Pengujian Klaim Adaptivitas *Gaussian Mixture Model* untuk *Background Subtraction* pada Dataset CDnet 2014

Tio Rizky Almunazir
NIM 26/589483/PPA/07359
Magister Kecerdasan Artifisial
Departemen Ilmu Komputer dan Elektronika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Gadjah Mada
tiorizkyalmunazir@mail.ugm.ac.id

***Ringkasan*—*Background subtraction* pada kamera statis sulit dilakukan ketika latar ikut berubah, misalnya karena air yang bergerak, bayangan, dan salju. Laporan ini menguji klaim bahwa model campuran Gaussian adaptif lebih tahan terhadap perubahan latar dengan membandingkan *running average* (RA), GMM Stauffer–Grimson yang diimplementasikan sendiri (GMM-SG), dan MOG2 OpenCV pada 16 video dari kategori *dynamicBackground*, *shadow*, dan *badWeather* CDnet 2014 dengan tujuh metrik resmi CDnet. GMM-SG memperoleh rerata F-measure tertinggi (0,565), disusul RA (0,490) dan MOG2 (0,458). F-measure GMM-SG per kategori adalah 0,294, 0,679, dan 0,723, sedangkan MOG2 memperoleh 0,330, 0,676, dan 0,367. Analisis kesalahan menunjukkan bahwa deteksi bayangan MOG2 memberi label bayangan pada 63–70% piksel objek di video bersalju, dan mematikannya menaikkan F-measure MOG2 di *badWeather* menjadi 0,646. Klaim adaptivitas model campuran didukung terhadap model latar tunggal, tetapi keunggulannya lebih ditentukan oleh laju pembelajaran dan kalibrasi varians daripada oleh jumlah komponen adaptif.**

***Kata kunci*—*background subtraction*, *Gaussian mixture model*, MOG2, CDnet 2014, adaptivitas latar**

I. Pendahuluan

Background subtraction memisahkan objek bergerak (*foreground*) dari latar pada video yang direkam kamera statis. Metode ini menjadi tahap awal pada sistem pengawasan video dan penghitungan kendaraan, karena tahap berikutnya seperti pelacakan dan klasifikasi objek hanya bekerja pada piksel yang ditandai sebagai *foreground*. Kesulitan utamanya muncul ketika latar tidak diam, misalnya pada dedaunan dan permukaan air yang terus bergerak, bayangan yang berpindah bersama objek, serta butiran salju atau hujan yang menutupi sebagian frame.

Stauffer dan Grimson [1] memodelkan setiap piksel sebagai campuran beberapa distribusi Gaussian yang diperbarui secara daring. Piksel pada daun yang bergoyang, misalnya, bergantian menampilkan warna daun dan warna langit. Model dengan satu nilai rerata akan selalu menganggap salah satunya sebagai objek, sedangkan GMM dapat menyimpan keduanya sebagai komponen latar. Zivkovic [2] kemudian memilih jumlah komponen setiap piksel secara otomatis, sehingga piksel dengan latar sederhana cukup diwakili satu komponen, dan implementasinya tersedia di OpenCV sebagai MOG2 [3].

Kedua makalah tersebut mengklaim bahwa model campuran adaptif mengikuti perubahan latar lebih baik daripada model latar tunggal. Klaim ini perlu diuji ulang pada dataset yang memisahkan jenis tantangan ke dalam kategori berbeda, karena keunggulan pada satu jenis perubahan latar belum tentu berlaku pada jenis lain. Penelitian ini membandingkan *running average*, GMM Stauffer–Grimson yang diimplementasikan sendiri, dan MOG2 pada 16 video dari tiga kategori CDnet 2014 [4].

Kontribusi laporan ini adalah sebagai berikut.

- Implementasi GMM Stauffer–Grimson tervektorisasi yang memproses semua piksel sekaligus, beserta evaluator CDnet yang diuji dengan dua prediktor buatan.
- Perbandingan tiga metode pada 16 video dengan tujuh metrik CDnet dan analisis per kategori tantangan.
- Analisis sensitivitas laju pembelajaran α pada satu video dari setiap kategori, serta analisis kesalahan pada piksel bayangan dan pada deteksi bayangan MOG2 di video bersalju.

II. Tinjauan Pustaka

A. Running Average

Running average menyimpan satu citra latar B_t yang diperbarui dengan

$$B_t = (1 - \alpha)\, B_{t-1} + \alpha\, I_t, \tag{1}$$

dengan I_t citra masukan dan $\alpha \in (0, 1]$ laju pembelajaran. Sebuah piksel diklasifikasikan sebagai *foreground* jika $|I_t - B_{t-1}| > \tau$. Nilai α mengatur kecepatan adaptasi. Dengan $\alpha = 1$, citra latar selalu sama dengan frame terakhir sehingga tidak ada piksel yang terdeteksi sebagai objek. Sebaliknya, α yang sangat kecil membuat latar lambat mengikuti perubahan: ketika pencahayaan ruangan berubah, hampir seluruh frame terdeteksi sebagai *foreground* selama kurang lebih $1/\alpha$ frame.

Model ini juga hanya menyimpan satu nilai per piksel, sehingga tidak dapat mewakili latar yang nilainya berganti-ganti seperti daun bergoyang.

B. GMM Stauffer–Grimson

Stauffer dan Grimson [1] memodelkan riwayat nilai setiap piksel X_t dengan K distribusi Gaussian. Komponen ke-k memiliki bobot w_k, rerata μ_k, dan kovarians $\sigma_k^2\mathbf{I}$, sehingga

$$P(X_t) = \sum_{k=1}^{K} w_{k,t}\,\eta\big(X_t;\mu_{k,t},\sigma_{k,t}^2\mathbf{I}\big)\,. \tag{2}$$

Sebuah piksel dinyatakan cocok dengan komponen k apabila jaraknya kurang dari $\lambda = 2{,}5$ simpangan baku, yaitu $\|X_t - \mu_k\|^2 < \lambda^2\sigma_k^2$. Jika beberapa komponen cocok, yang dipakai adalah komponen pertama menurut urutan prioritas di bawah. Bobot semua komponen diperbarui dengan

$$w_{k,t} = (1-\alpha)\,w_{k,t-1} + \alpha\,M_{k,t}, \tag{3}$$

dengan $M_{k,t} = 1$ untuk komponen yang cocok dan 0 untuk komponen lain. Rerata dan varians hanya diperbarui pada komponen yang cocok:

$$\mu_{k,t} = (1-\rho)\,\mu_{k,t-1} + \rho\,X_t, \tag{4}$$

$$\sigma_{k,t}^2 = (1-\rho)\,\sigma_{k,t-1}^2 + \rho\,\tfrac{1}{3}\|X_t - \mu_{k,t}\|^2. \tag{5}$$

Makalah asli memakai $\rho = \alpha\,\eta(X_t \mid \mu_k,\sigma_k)$. Nilai ini sangat kecil untuk citra 8 bit sehingga rerata hampir tidak bergerak, maka implementasi ini memakai pendekatan yang umum dipakai, $\rho = \alpha / w_{k,t}$ (dibatasi maksimum 1). Faktor $1/3$ merata-ratakan galat tiga kanal warna menjadi satu varians. Jika tidak ada komponen yang cocok, komponen dengan prioritas terendah diganti dengan Gaussian baru berpusat di X_t dengan varians awal besar σ_0^2 dan bobot kecil w_0, lalu bobot dinormalisasi.

Komponen kemudian diurutkan menurut w_k/σ_k. Komponen yang sering muncul dan stabil berada di urutan atas. Komponen latar adalah B komponen pertama,

$$B = \arg\min_{b}\left(\sum_{k=1}^{b} w_k > T\right), \tag{6}$$

dan piksel dinyatakan *foreground* jika tidak cocok dengan satu pun dari B komponen tersebut. Ambang T menentukan seberapa banyak variasi yang diterima sebagai latar. Dengan T kecil hanya satu komponen yang menjadi latar, sedangkan T besar memungkinkan latar bimodal seperti daun dan langit.

C. Zivkovic dan MOG2

Zivkovic [2] mempertahankan bentuk model campuran yang sama, tetapi bobot diperbarui dengan suku prior Dirichlet negatif,

$$\hat{\pi}_m \leftarrow \hat{\pi}_m + \alpha\,(o_m - \hat{\pi}_m) - \alpha\,c_T, \tag{7}$$

dengan $o_m = 1$ untuk komponen yang cocok dan c_T konstanta kecil. Komponen yang bobotnya menjadi negatif dibuang. Akibatnya, jumlah komponen setiap piksel ditentukan oleh data: piksel latar yang stabil cukup diwakili satu komponen, sedangkan piksel dengan latar dinamis menyimpan beberapa komponen hingga batas maksimum. Laju pembelajaran dikaitkan dengan panjang riwayat, $\alpha \approx 1/\mathrm{history}$, dan kecocokan diuji dengan kuadrat jarak Mahalanobis yang dibandingkan dengan `varThreshold`. Zivkovic dan van der Heijden [3] kemudian memberi dasar teoretis untuk pemilihan jumlah komponen ini.

Implementasi OpenCV juga menyediakan deteksi bayangan. Piksel yang tidak cocok dengan latar diperiksa ulang: jika warnanya merupakan versi lebih gelap dari komponen latar dengan distorsi kromatik kecil, piksel diberi label bayangan (nilai 127), bukan objek (nilai 255). Gagasan ini mengikuti metode deteksi bayangan yang dibandingkan oleh Prati dkk. [6]. Model *running average* dan GMM Stauffer–Grimson tidak memiliki mekanisme ini.

III. Metodologi

A. Dataset dan Protokol Evaluasi

Eksperimen memakai tiga kategori CDnet 2014 [4]: *dynamicBackground* (boats, canoe, fall, fountain01, fountain02, overpass), *shadow* (backdoor, bungalows, busStation, copyMachine, cubicle, peopleInShade), dan *badWeather* (blizzard, skating, snowFall, wetSnow), sehingga total terdapat 16 video.

Setiap video menyediakan rentang evaluasi (*temporal ROI*). Semua frame sejak frame pertama diproses oleh model, tetapi hanya frame di dalam rentang tersebut yang dinilai. Model latar dibangun dari frame yang telah diamati. Jika pemrosesan baru dimulai pada frame pertama rentang evaluasi, model hanya mengenal satu frame, dan objek yang kebetulan hadir pada frame itu ikut menjadi bagian latar. Frame sebelum rentang evaluasi karenanya berfungsi sebagai masa pemanasan (*warm-up*). Frame sesudah rentang evaluasi tidak diproses karena tidak memengaruhi frame mana pun yang dinilai.

Label *ground truth* diperlakukan sesuai protokol CDnet: nilai 255 (*motion*) sebagai positif, nilai 0 (*static*) dan 50 (*hard shadow*) sebagai negatif, sedangkan nilai 85 (di luar ROI) dan 170 (*unknown*) tidak dihitung. Keluaran MOG2 bernilai 127 (bayangan) diperlakukan sebagai negatif. Bayangan merupakan efek pencahayaan, bukan objek, sehingga metode tanpa deteksi bayangan seperti *running average* dan GMM Stauffer–Grimson berpotensi menghasilkan positif palsu pada piksel bayangan.

B. Metode yang Dibandingkan

Running average diimplementasikan pada citra skala abu-abu dengan $\alpha = 0{,}01$ dan $\tau = 30$. Citra latar disimpan dalam tipe `float32`. Pembaruan latar dengan α kecil sering bernilai kurang dari satu tingkat intensitas sehingga akan hilang akibat pembulatan pada `uint8`; pengurangan pada `uint8` juga dapat mengalami *overflow*. GMM Stauffer–Grimson diimplementasikan sendiri pada ruang warna RGB dengan $K = 3$, $\alpha = 0{,}01$, $T = 0{,}7$, $\lambda = 2{,}5$, varians awal $\sigma_0^2 = 30^2$, bobot awal komponen baru $w_0 = 0{,}05$, dan batas bawah varians 4^2 agar komponen tidak menyempit tanpa batas pada piksel yang sangat stabil. Laju pembaruan rerata dan varians memakai $\rho = \alpha / w_k$. Semua piksel diproses serentak dalam

Tabel I
TUJUH METRIK EVALUASI CDNET

Metrik	Rumus
Recall (Re)	$TP/(TP+FN)$
Specificity (Sp)	$TN/(TN+FP)$
FPR	$FP/(FP+TN)$
FNR	$FN/(TP+FN)$
PWC	$100\,(FN+FP)/(TP+FN+FP+TN)$
Precision (Pr)	$TP/(TP+FP)$
F-measure	$2\,\mathrm{Pr}\,\mathrm{Re}/(\mathrm{Pr}+\mathrm{Re})$

bentuk tensor PyTorch berukuran $N \times K$, dengan N jumlah piksel, sehingga tidak ada perulangan per piksel. MOG2 memakai `cv2.createBackgroundSubtractorMOG2` dengan `history` $=$ 500, `varThreshold` $=$ 16, dan `detectShadows` $=$ `True`; parameter lain mengikuti bawaan OpenCV, termasuk laju pembelajaran otomatis. Ketiga metode menerima frame yang sama dalam satu kali pembacaan video.

C. Metrik

Evaluasi memakai tujuh metrik resmi CDnet pada Tabel I. Nilai TP, FP, TN, dan FN dijumlahkan dari seluruh frame yang dinilai dalam satu video, lalu metrik dihitung sekali dari total tersebut. Skor kategori merupakan rerata skor video di dalam kategori itu. Banyak frame tidak memuat objek bergerak sama sekali, misalnya frame 400 pada video backdoor, sehingga $TP + FN = 0$ dan Recall per frame tidak terdefinisi.

F-measure dipakai sebagai metrik utama dalam pembahasan. Pada video backdoor, piksel objek hanya mencakup sekitar 2% dari seluruh piksel yang dinilai. Model yang selalu mengeluarkan latar memperoleh Specificity 1 dan PWC 1,99%, padahal Recall-nya nol. F-measure tidak terpengaruh dominasi kelas latar karena hanya bergantung pada Precision dan Recall.

D. Validasi Evaluator

Evaluator diuji dengan dua prediktor buatan pada video backdoor. Prediktor sempurna, yang menyalin label *motion* dari *ground truth*, menghasilkan Recall, Precision, dan F-measure bernilai 1 serta FPR dan PWC bernilai 0. Prediktor yang selalu mengeluarkan latar menghasilkan $TP = 0$, $FN = 2.024.597$, Recall 0, Specificity 1, dan F-measure 0. Kedua hasil tersebut sesuai dengan nilai yang diharapkan secara analitis.

IV. HASIL

Tabel II merangkum F-measure rerata per kategori. GMM Stauffer–Grimson (GMM-SG) memperoleh rerata tertinggi, 0,565, disusul *running average* (RA) 0,490 dan MOG2 0,458. Urutan ini tidak sama di setiap kategori: MOG2 unggul tipis pada *dynamicBackground*, GMM-SG dan MOG2 hampir sama pada *shadow*, sedangkan pada *badWeather* MOG2 jatuh jauh di bawah dua metode lain. Tabel III memuat ketujuh metrik per kategori, dan Tabel IV memuat F-measure setiap video.

Gambar 1 memperlihatkan satu frame dari dua video setiap kategori. Frame dipilih otomatis sebagai frame evaluasi (kelipatan 50) dengan jumlah piksel *motion* terbanyak, sehingga pemilihan tidak dipengaruhi hasil metode. Warna hijau menandai TP, merah FP, biru FN, dan abu-abu piksel yang tidak dinilai.

Tabel II
F-MEASURE RERATA PER KATEGORI

Kategori	RA	GMM-SG	MOG2
dynamicBackground	0,206	0,294	**0,330**
shadow	0,633	**0,679**	0,676
badWeather	0,633	**0,723**	0,367
Rerata	0,490	**0,565**	0,458

Gambar 2 memperlihatkan pengaruh laju pembelajaran α pada satu video dari setiap kategori. Untuk MOG2, nilai α dipasang sebagai `learningRate`, menggantikan laju otomatis. RA relatif datar pada canoe dan mencapai puncak pada $\alpha = 0{,}01$–$0{,}03$ di dua video lain, GMM-SG pada $\alpha = 0{,}003$–$0{,}01$, sedangkan MOG2 turun tajam untuk $\alpha \geq 0{,}03$ dan hampir nol pada $\alpha = 0{,}1$ (F-measure 0,001–0,003 pada ketiga video). Pada canoe, GMM-SG naik dari 0,395 ($\alpha = 0{,}01$) menjadi 0,661 ($\alpha = 0{,}003$).

Dua analisis tambahan dijalankan untuk menjelaskan pola pada Tabel II. Pertama, MOG2 pada *badWeather* dijalankan ulang dengan dan tanpa deteksi bayangan, sambil mencatat label yang diberikan MOG2 pada piksel objek (Tabel V). Kedua, pada kategori *shadow* dihitung laju FP di piksel *hard shadow* (label GT 50), yaitu proporsi piksel bayangan yang ditandai sebagai objek (Tabel VI). Video backdoor dan copyMachine tidak memiliki piksel berlabel 50 pada rentang evaluasi sehingga tidak dicantumkan.

V. PEMBAHASAN

Klaim yang diuji adalah bahwa model campuran adaptif mengikuti perubahan latar lebih baik daripada model latar tunggal. Secara umum klaim ini didukung: GMM-SG mengungguli RA di ketiga kategori, dan MOG2 mengungguli RA di dua kategori. Besarnya keunggulan dan penyebabnya berbeda pada setiap kategori.

A. dynamicBackground

Pada kategori ini model campuran menurunkan FPR dari 0,070 (RA) menjadi 0,024 (GMM-SG) dan 0,023 (MOG2), dan PWC turun dari 7,26% menjadi 2,96% dan 2,64%. Precision hampir dua kali lipat, dari 0,129 menjadi 0,235 dan 0,241, sementara Recall ketiga metode berada pada rentang yang sama (0,61–0,68). Penurunan FP ini sesuai dengan klaim: riak air dan semburan air mancur dapat disimpan sebagai komponen latar tambahan. Baris canoe pada Gambar 1 memperlihatkannya, karena bintik merah RA menutupi hampir seluruh permukaan air, sedangkan GMM-SG hanya menyisakan sedikit.

Meski begitu, F-measure kategori ini tetap rendah (paling tinggi 0,330) dan Precision di bawah 0,25, artinya sekitar tiga dari empat piksel yang ditandai objek sebenarnya latar. Video fountain01 dan boats tetap sulit bagi ketiga metode (F-measure di bawah 0,17). Gambar 1 juga menunjukkan masalah lain

Tabel III
TUJUH METRIK CDNET, RERATA PER KATEGORI

Kat.	Metode	Re	Sp	FPR	FNR	PWC	Pr	F
dynBG	RA	0,685	0,930	0,070	0,316	7,26	0,129	0,206
	GMM-SG	0,609	0,976	0,024	0,391	2,96	0,235	0,294
	MOG2	0,674	0,977	0,023	0,326	2,64	0,241	0,330
shadow	RA	0,681	0,980	0,020	0,319	3,37	0,602	0,633
	GMM-SG	0,624	0,991	0,009	0,376	2,58	0,791	0,679
	MOG2	0,665	0,990	0,010	0,335	2,56	0,743	0,676
badW	RA	0,598	0,986	0,014	0,402	1,96	0,781	0,633
	GMM-SG	0,634	0,997	0,003	0,366	0,96	0,851	0,723
	MOG2	0,351	0,991	0,009	0,650	1,79	0,526	0,367

Tabel IV
F-MEASURE PER VIDEO

Kategori	Video	RA	GMM-SG	MOG2
dynBG	boats	0,079	0,076	**0,165**
	canoe	0,269	0,395	**0,605**
	fall	0,165	**0,448**	0,342
	fountain01	0,029	**0,065**	0,043
	fountain02	0,334	**0,373**	0,280
	overpass	0,358	0,408	**0,548**
shadow	backdoor	0,718	**0,885**	0,715
	bungalows	0,699	**0,785**	0,784
	busStation	0,590	0,517	**0,629**
	copyMachine	**0,546**	0,495	0,506
	cubicle	0,538	**0,710**	0,682
	peopleInShade	0,707	0,679	**0,744**
badW	blizzard	0,612	**0,773**	0,111
	skating	0,578	**0,763**	0,744
	snowFall	0,666	**0,691**	0,096
	wetSnow	**0,675**	0,665	0,517

Tabel V
MOG2 PADA *badWeather* DENGAN DAN TANPA DETEKSI BAYANGAN. KOLOM "KE 127" ADALAH PROPORSI PIKSEL OBJEK YANG DIBERI LABEL BAYANGAN.

Video	F (bayangan aktif)	F (nonaktif)	ke 127
blizzard	0,111	0,762	0,703
skating	0,744	0,793	0,118
snowFall	0,096	0,362	0,633
wetSnow	0,517	0,666	0,278
Rerata	0,367	0,646	–

pada GMM-SG: sebagian besar badan kano berwarna biru (FN). Kano bergerak lambat sehingga, dengan $\alpha = 0{,}01$, warnanya cepat diserap menjadi komponen latar. Gambar 2 menguatkan dugaan ini, sebab F-measure GMM-SG pada canoe naik dari 0,395 menjadi 0,661 ketika α diturunkan ke 0,003. Keunggulan MOG2 pada kategori ini sebagian berasal dari laju pembelajaran bawaan OpenCV, $1/\min(t, \text{history})$, yang setelah 500 frame bernilai 0,002, jauh lebih kecil daripada α GMM-SG. Pada α yang disamakan (0,003), GMM-SG justru lebih tinggi daripada MOG2 pada ketiga video uji sensitivitas (0,661 vs 0,575 pada canoe, 0,779 vs 0,765 pada backdoor, 0,668 vs 0,509 pada wetSnow). Jadi, keunggulan MOG2 di sini belum dapat dikaitkan dengan jumlah komponen adaptif.

Tabel VI
LAJU FP PADA PIKSEL *hard shadow* (GT 50) DAN PROPORSI PIKSEL BAYANGAN YANG DIBERI LABEL 127 OLEH MOG2

Video	RA	GMM-SG	MOG2	MOG2 ke 127
bungalows	1,000	1,000	0,999	0,001
busStation	0,232	0,213	0,087	0,186
cubicle	0,909	0,711	0,313	0,500
peopleInShade	0,947	0,975	0,929	0,035

B. shadow

GMM-SG (0,679) dan MOG2 (0,676) hampir sama dan keduanya di atas RA (0,633). Selisih terhadap RA datang dari Precision (0,602 menjadi 0,791 dan 0,743) dan FPR yang turun lebih dari separuh. Deteksi bayangan MOG2 ternyata tidak memberi keunggulan rerata yang terlihat. Tabel VI menunjukkan alasannya. Pada cubicle dan busStation, MOG2 memberi label bayangan pada 50% dan 18,6% piksel bayangan, sehingga laju FP di piksel bayangan turun menjadi 0,313 dan 0,087, lebih rendah daripada RA (0,909 dan 0,232) dan GMM-SG (0,711 dan 0,213). Pada bungalows dan peopleInShade, MOG2 hampir tidak pernah mengenali bayangan (0,1% dan 3,5%) dan menandai 99,9% dan 92,9% piksel bayangan sebagai objek, sama buruknya dengan dua metode lain. Uji bayangan OpenCV mensyaratkan piksel bayangan tidak lebih gelap dari batas rasio kecerahan tertentu (bawaan 0,5). Bayangan keras yang sangat gelap kemungkinan melewati batas ini dan tetap dianggap objek, tetapi dugaan ini belum diuji dengan mengubah ambang tersebut.

Video backdoor memberi contoh kebalikannya. GMM-SG mencapai F-measure 0,885, tertinggi di antara semua video, sedangkan MOG2 hanya 0,715. Gambar 2 menunjukkan bahwa MOG2 pada backdoor mencapai 0,797 ketika $\alpha = 0{,}01$, sehingga selisih ini juga lebih banyak ditentukan oleh laju pembelajaran daripada oleh mekanisme bayangan.

C. badWeather

GMM-SG unggul paling jelas pada kategori ini (0,723 terhadap 0,633 untuk RA). Precision GMM-SG 0,851 dan FPR 0,003, terendah dari semua kombinasi metode dan kategori.



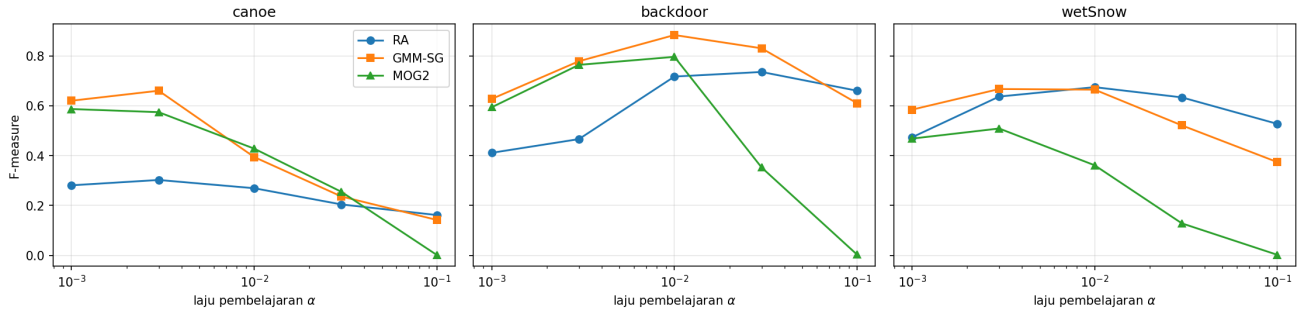
Gambar 1. Contoh kualitatif. Kolom 3–5 adalah peta kesalahan tiap metode: hijau TP, merah FP, biru FN, abu-abu tidak dinilai.

Batas bawah varians 15^2 pada jarak tiga kanal membuat perubahan kecerahan kecil akibat butiran salju tetap cocok dengan komponen latar. Recall RA (0,598) lebih rendah daripada GMM-SG, dan pada skating RA meninggalkan daerah FP besar di samping orang (Gambar 1), kemungkinan sisa objek yang lambat hilang dari citra latar.

MOG2 justru turun ke 0,367. Tabel V menunjukkan penyebab utamanya: pada blizzard 70,3% dan pada snowFall 63,3% piksel objek diberi label bayangan. Kemungkinan besar kendaraan yang redup di tengah salju tampil sebagai versi lebih gelap dari latar yang putih, sehingga lolos uji bayangan. Dengan deteksi bayangan dimatikan, F-measure MOG2 naik menjadi 0,762 pada blizzard dan rerata kategori naik dari 0,367 menjadi 0,646, meski masih di bawah GMM-SG. Pada snowFall masalah kedua tetap ada, yaitu Precision rendah (0,234 tanpa deteksi bayangan) akibat butiran salju yang ditandai sebagai objek, terlihat sebagai bintik merah pada baris snowFall Gambar 1. Jadi deteksi bayangan, yang dirancang untuk kategori *shadow*, merugikan kategori *badWeather*.

D. Catatan Implementasi

Versi pertama GMM-SG menghitung varians per kanal (jarak kuadrat dibagi 3) dengan batas bawah 4^2, tetapi uji kecocokan tetap memakai jarak total tiga kanal. Dengan kalibrasi ini, derau biasa sering melewati ambang $2{,}5\sigma$, dan rerata



Gambar 2. F-measure terhadap laju pembelajaran α (skala log) pada canoe, backdoor, dan wetSnow.

F-measure kategori hanya 0,069 (*dynamicBackground*), 0,418 (*shadow*), dan 0,344 (*badWeather*). Setelah varians dihitung dari jarak total, seperti pada implementasi OpenCV, angkanya naik menjadi 0,294, 0,679, dan 0,723. Perbedaan sebesar ini, yang lebih besar daripada selisih antarmetode, menunjukkan bahwa perbandingan metode latar sangat bergantung pada rincian implementasi. Klaim adaptivitas dari satu makalah sebaiknya diuji dengan implementasi dan parameter yang dilaporkan lengkap.

E. Keterbatasan

Setiap metode dijalankan dengan satu set parameter tanpa pascapemrosesan (misalnya filter median atau operasi morfologi), dan laju pembelajaran MOG2 pada eksperimen utama tidak disamakan dengan dua metode lain. Uji sensitivitas hanya mencakup satu video per kategori, dan analisis bayangan hanya mencakup empat video yang memiliki label *hard shadow*.

VI. Kesimpulan

Model campuran Gaussian terbukti lebih adaptif daripada *running average* pada ketiga kategori CDnet yang diuji. GMM Stauffer–Grimson memperoleh rerata F-measure 0,565, dibanding 0,490 untuk RA dan 0,458 untuk MOG2. Pada *dynamicBackground*, model campuran memangkas FPR sekitar tiga kali, tetapi F-measure tetap di bawah 0,34 dan sangat bergantung pada α. Pada *shadow*, GMM-SG dan MOG2 setara (0,679 dan 0,676) dan deteksi bayangan MOG2 hanya membantu pada bayangan yang tidak terlalu gelap. Pada *badWeather*, GMM-SG tertinggi (0,723), sedangkan MOG2 turun ke 0,367 karena 63–70% piksel objek pada blizzard dan snowFall diberi label bayangan. Mekanisme tambahan MOG2, yaitu jumlah komponen adaptif dan deteksi bayangan, tidak memberi keunggulan yang konsisten atas GMM dengan $K = 3$ tetap pada eksperimen ini. Laju pembelajaran dan kalibrasi varians berpengaruh lebih besar terhadap hasil daripada pilihan antara kedua model campuran.

Pustaka

[1] C. Stauffer and W. E. L. Grimson, “Adaptive background mixture models for real-time tracking,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 1999, vol. 2, pp. 246–252.

[2] Z. Zivkovic, “Improved adaptive Gaussian mixture model for background subtraction,” in *Proc. Int. Conf. Pattern Recognition (ICPR)*, 2004, vol. 2, pp. 28–31.

[3] Z. Zivkovic and F. van der Heijden, “Efficient adaptive density estimation per image pixel for the task of background subtraction,” *Pattern Recognition Letters*, vol. 27, no. 7, pp. 773–780, 2006.

[4] Y. Wang, P.-M. Jodoin, F. Porikli, J. Konrad, Y. Benezeth, and P. Ishwar, “CDnet 2014: An expanded change detection benchmark dataset,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2014, pp. 393–400.

[5] N. Goyette, P.-M. Jodoin, F. Porikli, J. Konrad, and P. Ishwar, “Changedetection.net: A new change detection benchmark dataset,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2012, pp. 1–8.

[6] A. Prati, I. Mikić, M. M. Trivedi, and R. Cucchiara, “Detecting moving shadows: Algorithms and evaluation,” *IEEE Trans. Pattern Analysis and Machine Intelligence*, vol. 25, no. 7, pp. 918–923, 2003.